

## TAREA M32-CD-PAULO ANDRES OSSA BENITEZ

Generación de wireframe (Miro, Slides) sobre 1 reporte con 5 elementos

Esta tarea queda pendiente hasta que pongan la lección correspondiente al diseño de Wireframes con Miro en el contenido del programa

Generar un archivo tipo Notebook de Python que contenga el código fuente de

Leer archivo [fifa\\_edu.csv](#)

Elemento 1: Obtener matriz de correlación y dejarla como heat map

Elemento 2: Gráfico de Correlación que responda – “Cuál es la relación entre la edad y el overall?” – explicar la salida

Elemento 3: Generar un gráfico de barras por club que indique el número de jugadores

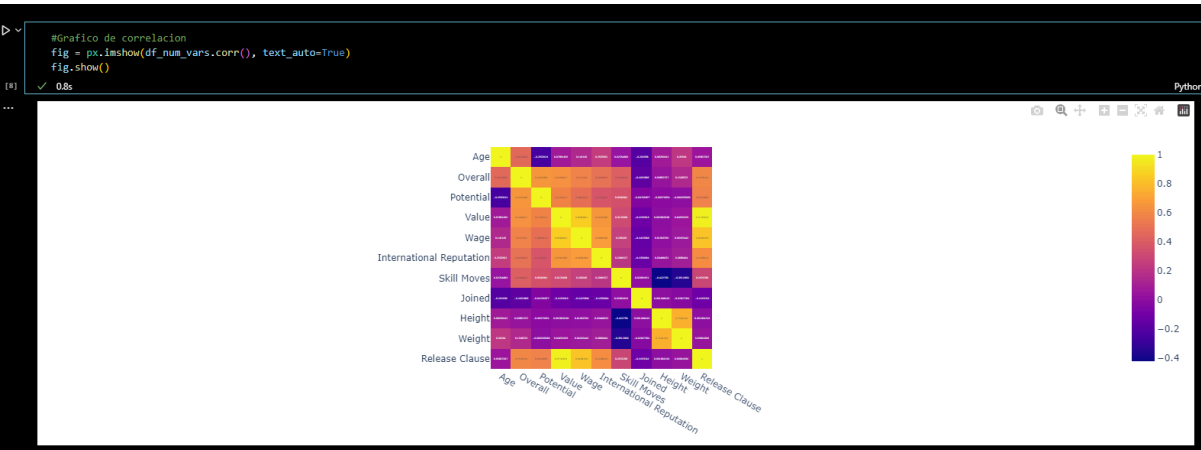
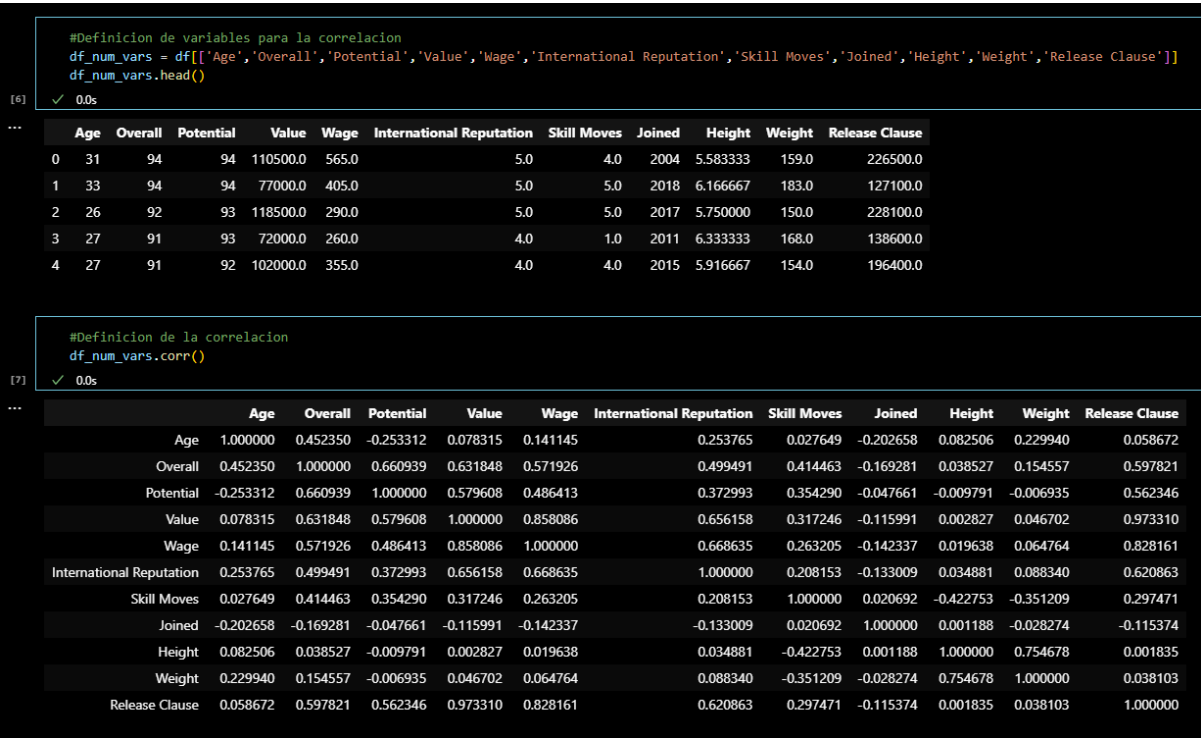
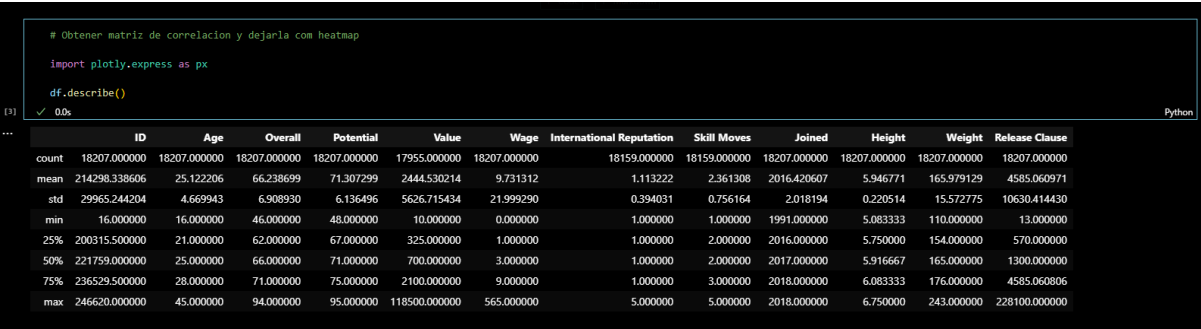
Elemento 4: Hacer un gráfico multipanel que indique la relación altura (height) vs skill moves, siendo la variable del panel si es zurdo o derecho

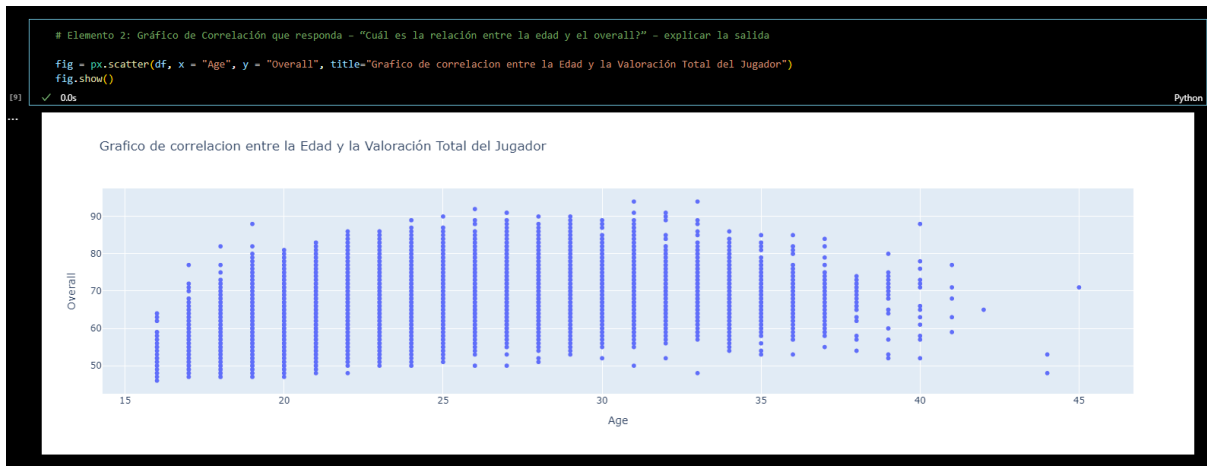
Elemento 5: Un gráfico que crea importante para mostrar a los potenciales cracks

```
# Leer archivo
import pandas as pd
df = pd.read_csv('fifa_edu.csv')

df.head()
```

	ID	Name	Age	Nationality	Overall	Potential	Club	Value	Wage	Preferred Foot	International Reputation	Skill Moves	Position	Joined	Contract Valid Until	Height	Weight	Release Clause
0	158023	L. Messi	31	Argentina	94	94	FC Barcelona	110500.0	565.0	Left	5.0	4.0	RF	2004	2021-01-01	5.583333	159.0	226500.0
1	20801	Cristiano Ronaldo	33	Portugal	94	94	Juventus	77000.0	405.0	Right	5.0	5.0	ST	2018	2022-01-01	6.166667	183.0	127100.0
2	190871	Neymar Jr	26	Brazil	92	93	Paris Saint-Germain	118500.0	290.0	Right	5.0	5.0	LW	2017	2022-01-01	5.750000	150.0	228100.0
3	193080	De Gea	27	Spain	91	93	Manchester United	72000.0	260.0	Right	4.0	1.0	GK	2011	2020-01-01	6.333333	168.0	138600.0
4	192985	K. De Bruyne	27	Belgium	91	92	Manchester City	102000.0	355.0	Right	4.0	4.0	RCM	2015	2023-01-01	5.916667	154.0	196400.0





Media del Overall es 66.23 y de la Edad es 25 años

Con esto se pueden inferir varias cosas. Hasta los 25 años se tienen marcas de Overall por debajo de los 50 puntos, salvo casos aislados mas adelante. A partir de ahí valoración mínima sube y es de anotar que entre mas edad, las puntuaciones más bajas pertenecen a outliers. En cuanto a la valoración mas altas esta entre los 26 y 33 años, que se puede inferir que son los años más productivos en general de los jugadores.

A partir de los 34 años comienzan a disminuir el número de jugadores lo que supone que los 35 años es como la edad donde se comienzan a retirar los jugadores, y comienzan a perder valor, aunque los mínimos no bajan de 50 como pasa antes de los 25.

La reducción más fuerte de jugadores esta desde los 40 años en adelante, no habiendo mayores de 45 años. Definitivamente la data marca 3 puntos importantes.

1. Cuando son muy jóvenes falta experiencia, por tanta la valoración no es alta.
2. A partir de los 25 ya se obtiene mas experiencia y se tiene mucho vigor por lo que la valoración sube y se mantiene así hasta los 33 años.
3. A partir de los 33 años, pesa la experiencia lo cual tiene su recompensa en valoración, pero comienza a darse las bajas de jugadores y son pocos los que juegan despues de los 35 años.

```
#Elemento 3: Generar un gráfico de barras por club que indique el número de jugadores
df_clubes = df.groupby('Club').size().rename('Num_Jugadores').reset_index().sort_values(by='Num_Jugadores', ascending=False)
df_clubes
```

✓ 0.0s

	Club	Num_Jugadores
86	Borussia Dortmund	33
583	Tottenham Hotspur	33
134	Chelsea	33
605	Valencia CF	33
206	Everton	33
...	...	...
254	Fluminense	20
88	Botafogo	20
361	Limerick FC	19
543	Sligo Rovers	19
188	Derry City	18

651 rows × 2 columns

Python

[illegible]

Python

The figure consists of two side-by-side dot plots. The left plot is titled 'Preferred Foot=Left' and the right plot is titled 'Preferred Foot=Right'. Both plots have 'Skill Moves' on the x-axis (values 1, 2, 3, 4, 5) and 'Height' on the y-axis (values 5, 5.5, 6, 6.5). Each plot shows a vertical cluster of blue dots for each skill move value, representing the heights of players who performed that number of skill moves. In the 'Preferred Foot=Left' plot, the dots for skill move 1 are clustered around 6.2, skill move 2 around 6.2, skill move 3 around 5.8, skill move 4 around 5.8, and skill move 5 around 5.8. In the 'Preferred Foot=Right' plot, the dots for skill move 1 are clustered around 6.2, skill move 2 around 6.2, skill move 3 around 6.2, skill move 4 around 6.2, and skill move 5 around 6.2.

#Elemento 5: Un gráfico que crea importante para mostrar a los potenciales cracks

#De acuerdo a las estadísticas que ya hemos visto, y basandonos en puntuaciones de variables mínimas que sean la media + la desviación standard, deberíamos ver potenciales cracks.

#Potential > 78

# Edad 26-33 años

# Overall >90

# International Reputation >1.6

# Release Clause > 70000

#Con estos datos nos refina la data y nos devuelve los mejores 23 jugadores de la base de datos.

df\_cracks = df[(df['Potential'] > 78 ) & (df['Age'] > 25) & (df['Age'] <= 33) & (df['Overall'] > 88) & (df['International Reputation'] > 1.6) & (df['Release Clause'] > 70000)].sort\_values(by='Age', df\_cracks

0.0sPython

ID	Name	Age	Nationality	Overall	Potential	Club	Value	Wage	Preferred Foot	International Reputation	Skill Moves	Position	Joined	Contract Valid Until	Height	Weight	Release Clause	
2	190871	Neymar Jr	26	Brazil	92	93	Paris Saint-Germain	118500.0	290.0	Right	5.0	5.0	LW	2017	2022-01-01	5.750000	150.0	228100.0
19	192119	T. Courtois	26	Belgium	89	90	Real Madrid	53500.0	240.0	Left	4.0	1.0	GK	2018	2024-01-01	6.500000	212.0	113700.0
18	192448	M. ter Stegen	26	Germany	89	92	FC Barcelona	58000.0	240.0	Right	3.0	1.0	GK	2014	2022-01-01	6.166667	187.0	123300.0
3	193080	De Gea	27	Spain	91	93	Manchester United	72000.0	260.0	Right	4.0	1.0	GK	2011	2020-01-01	6.333333	168.0	138600.0
4	192985	K. De Bruyne	27	Belgium	91	92	Manchester City	102000.0	355.0	Right	4.0	4.0	RCM	2015	2023-01-01	5.916667	154.0	196400.0
5	183277	E. Hazard	27	Belgium	91	91	Chelsea	93000.0	340.0	Right	4.0	4.0	LF	2012	2020-01-01	5.666667	163.0	172100.0
17	194765	A. Griezmann	27	France	89	90	Atlético Madrid	78000.0	145.0	Left	4.0	4.0	CAM	2014	2023-01-01	5.750000	161.0	165800.0
14	215914	N. Kanté	27	France	89	90	Chelsea	63000.0	225.0	Right	3.0	2.0	LDM	2016	2023-01-01	5.500000	159.0	121300.0
11	182521	T. Kroos	28	Germany	90	90	Real Madrid	76500.0	355.0	Right	4.0	3.0	LCM	2014	2022-01-01	6.000000	168.0	156800.0
10	188545	R. Lewandowski	29	Poland	90	90	FC Bayern Munchen	77000.0	205.0	Right	4.0	4.0	ST	2014	2021-01-01	6.000000	176.0	127100.0
20	189511	Sergio Busquets	29	Spain	89	89	FC Barcelona	51500.0	315.0	Right	4.0	3.0	CDM	2008	2023-01-01	6.166667	168.0	105600.0
23	153079	S. Agüero	30	Argentina	89	89	Manchester City	64500.0	300.0	Right	4.0	4.0	ST	2011	2021-01-01	5.666667	154.0	119300.0
21	179813	E. Cavani	31	Uruguay	89	89	Paris Saint-Germain	60000.0	200.0	Right	4.0	3.0	LS	2013	2020-01-01	6.083333	170.0	111000.0
7	176580	L. Suárez	31	Uruguay	91	91	FC Barcelona	80000.0	455.0	Right	5.0	3.0	RS	2014	2021-01-01	6.000000	190.0	164000.0
0	158023	L. Messi	31	Argentina	94	94	FC Barcelona	110500.0	565.0	Left	5.0	4.0	RF	2004	2021-01-01	5.583333	159.0	226500.0

Spaces: 4CRLFCell 9 of 14

